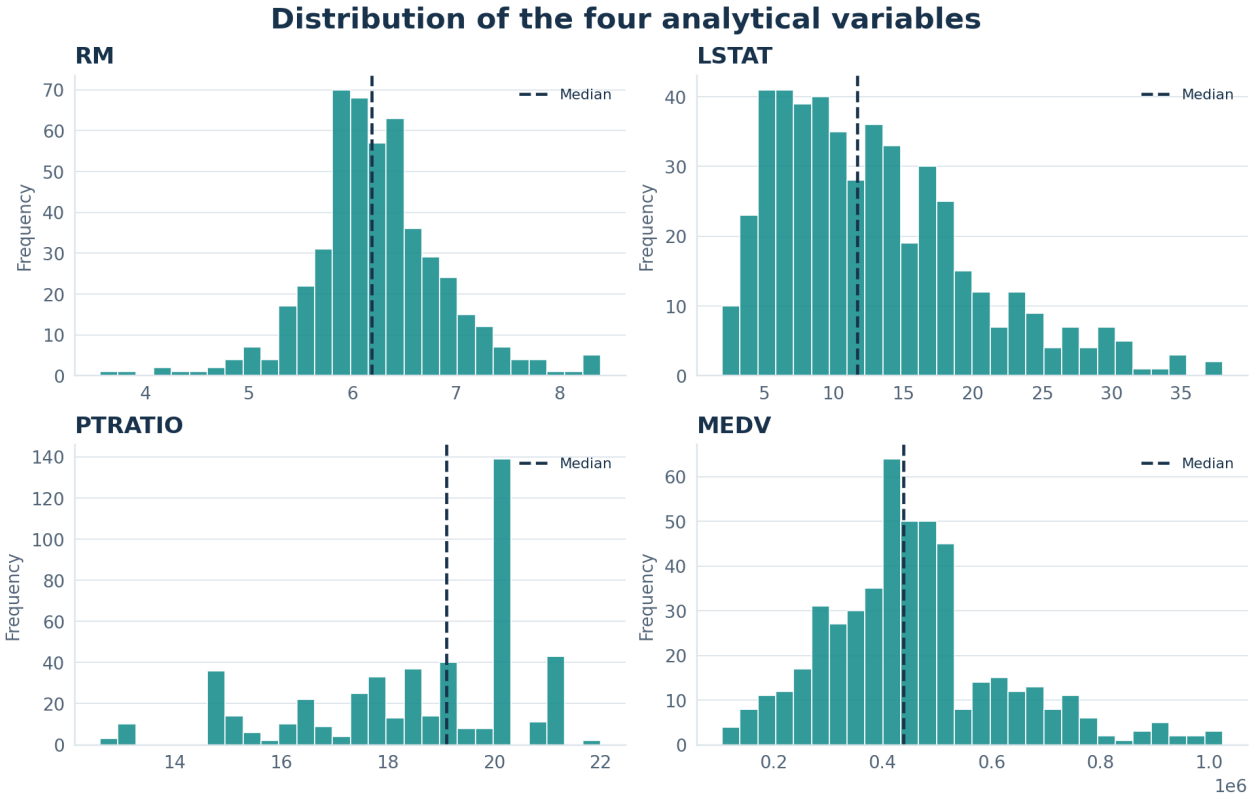
Analyse exploratoire et modélisation prédictive

Rapport explicatif fondé sur le tableau de bord Python fourni et le jeu de données CSV sur le logement.

Synthèse exécutive

489 observations complètes et quatre variables numériques sont incluses. Le tableau de bord utilise RM, LSTAT et PTRATIO comme variables explicatives, et MEDV comme variable cible par défaut. Le fichier CSV ne contient aucune valeur manquante dans ces champs et aucune ligne exactement dupliquée.

Résultat de référence : le modèle Random Forest obtient la plus faible RMSE sur l'échantillon de test (R^2 = 0,851 ; MAE = 44 053 ; RMSE = 57 229), avec la partition 80/20 spécifiée. Il s'agit d'un résultat reproductible sur une seule partition de test, et non d'une garantie pour de nouvelles observations.



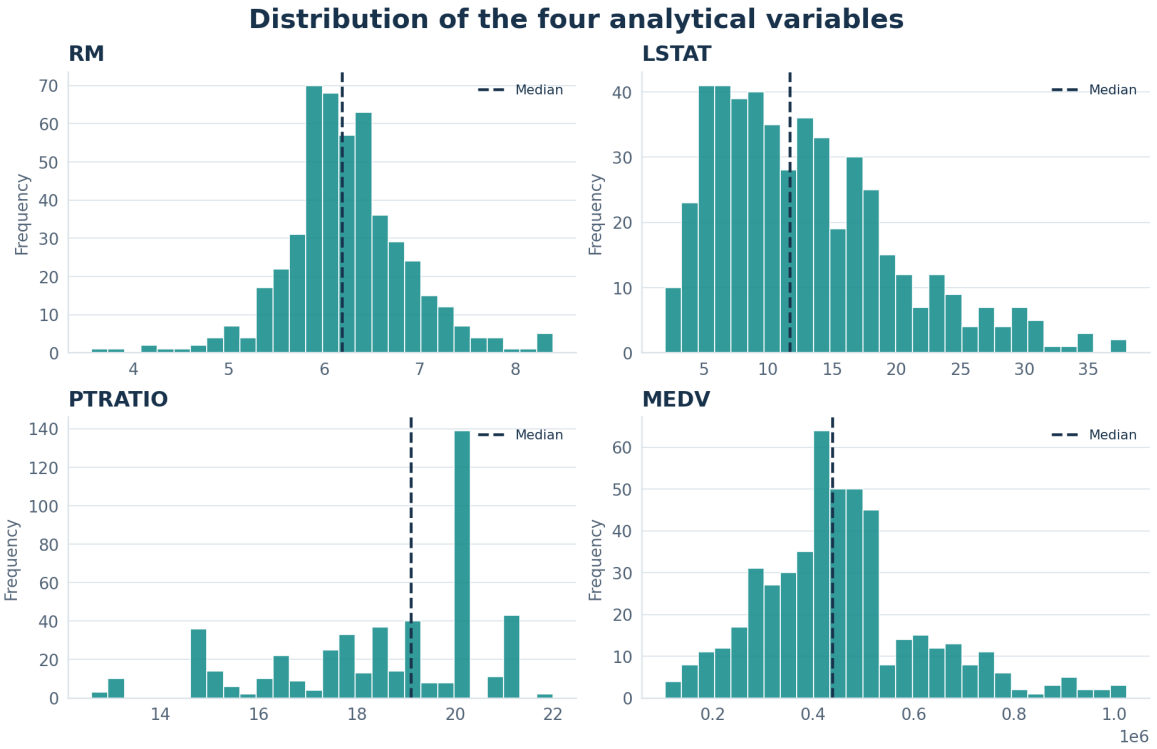
Précaution de mesure : le code affiche un symbole dollar pour MEDV dans certaines étiquettes du tableau de bord, mais le fichier CSV ne documente ni devise, ni zone géographique, ni date d'évaluation, ni méthode de mesure. Ce rapport traite donc MEDV comme une variable cible numérique enregistrée, sans supposer de devise ou de localisation.

01 | COMPRÉHENSION DES DONNÉES
Variables et statistiques descriptives

Les descriptions des variables ci-dessous suivent les définitions incluses dans le code du tableau de bord fourni.

Signification des champs

RM : nombre moyen de pièces par logement.
LSTAT : indicateur en pourcentage ; le tableau de bord le désigne comme le pourcentage de la population de statut socio-économique inférieur.
PTRATIO : ratio élèves-enseignant.
MEDV : variable cible correspondant à la valeur médiane enregistrée des biens immobiliers.
Ces quatre colonnes définissent le périmètre de l'analyse. Aucun identifiant géographique, âge du bien, type de propriété ou champ documentant la devise/l'unité n'est disponible. Ces caractéristiques ne peuvent pas être déduites des valeurs fournies.



Statistiques descriptives

Variable	Effectif	Moyenne	Écart-type	Minimum	Médiane	Maximum	Asymétrie
RM	489	6,24	0,64	3,56	6,18	8,40	0,08
LSTAT	489	12,94	7,08	1,98	11,69	37,97	0,91
PTRATIO	489	18,52	2,11	12,60	19,10	22,00	?0,82
MEDV	489	454 342,94	165 340,28	105 000,00	438 900,00	1 024 800,00	0,78

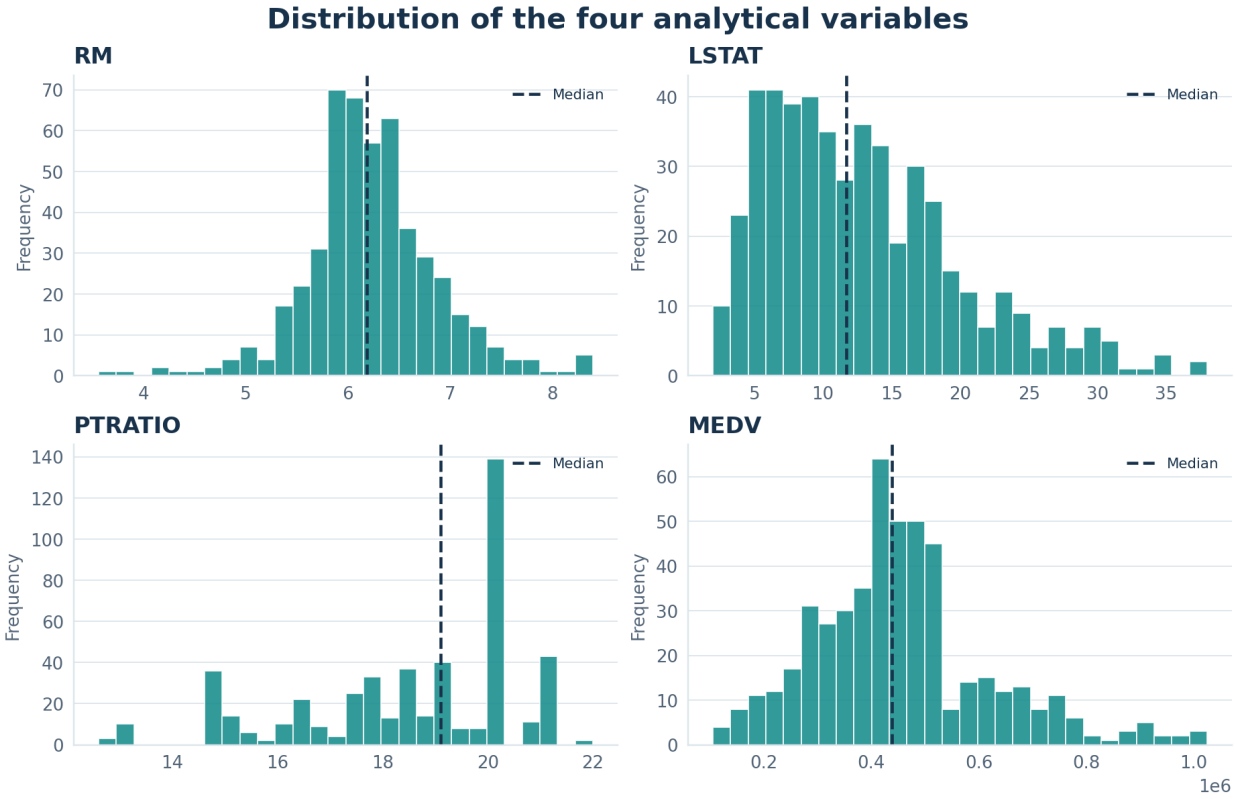
02 | EXPLORATION UNIVARIÉE
Forme des distributions et valeurs potentiellement atypiques

Les histogrammes montrent les profils de fréquence ; les diagrammes en boîte résument les médianes, les quartiles et les observations inhabituelles.

Comment lire ces graphiques

Il convient d'examiner la concentration, la dispersion, l'asymétrie et la présence éventuelle de plusieurs pics. Le diagramme en boîte résume la médiane et l'écart interquartile (IQR). La règle de détection par IQR signale les observations situées en dehors des bornes Q1 ? 1,5 × IQR ou Q3 + 1,5 × IQR.

Une observation signalée constitue une valeur candidate à examiner ; elle n'est pas automatiquement erronée. Les valeurs inhabituelles doivent être vérifiées à partir des données sources avant toute exclusion. Les valeurs extrêmes valides peuvent contenir des informations importantes.



Détection des valeurs potentiellement atypiques (1,5 × IQR)

Variable	Q1	Q3	Borne inférieure	Borne supérieure	Signalées
RM	5,88	6,58	4,84	7,62	22
LSTAT	7,37	17,12	?7,25	31,75	7
PTRATIO	17,40	20,20	13,20	24,40	13
MEDV	350 700,00	518 700,00	98 700,00	770 700,00	22

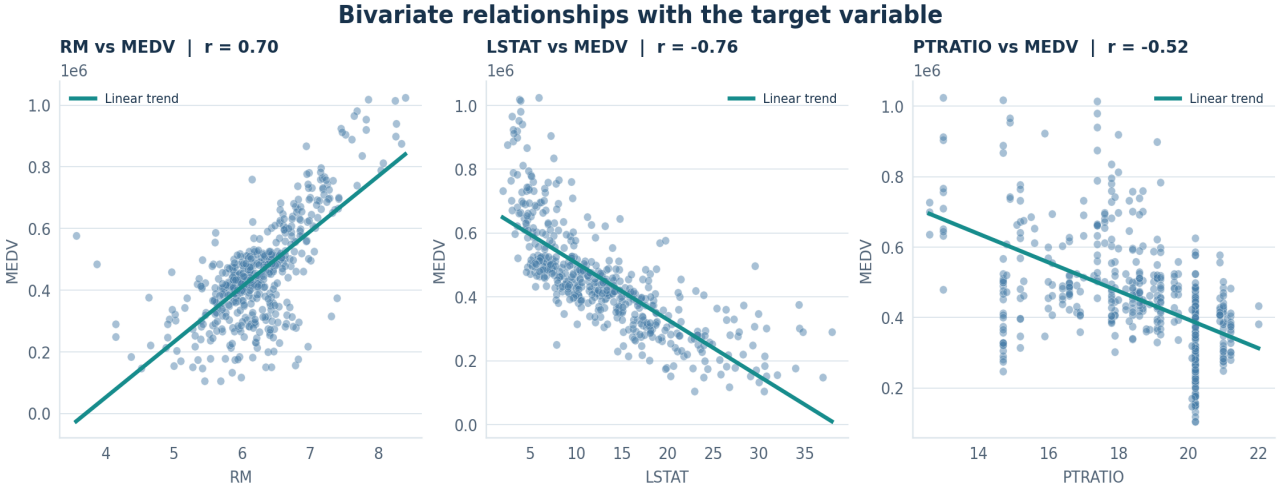
03 | EXPLORATION BIVARIÉE
Relations avec la variable cible

Les nuages de points représentent les observations ; les lignes de tendance résument la direction linéaire sans impliquer de causalité.

Interprétation variable par variable

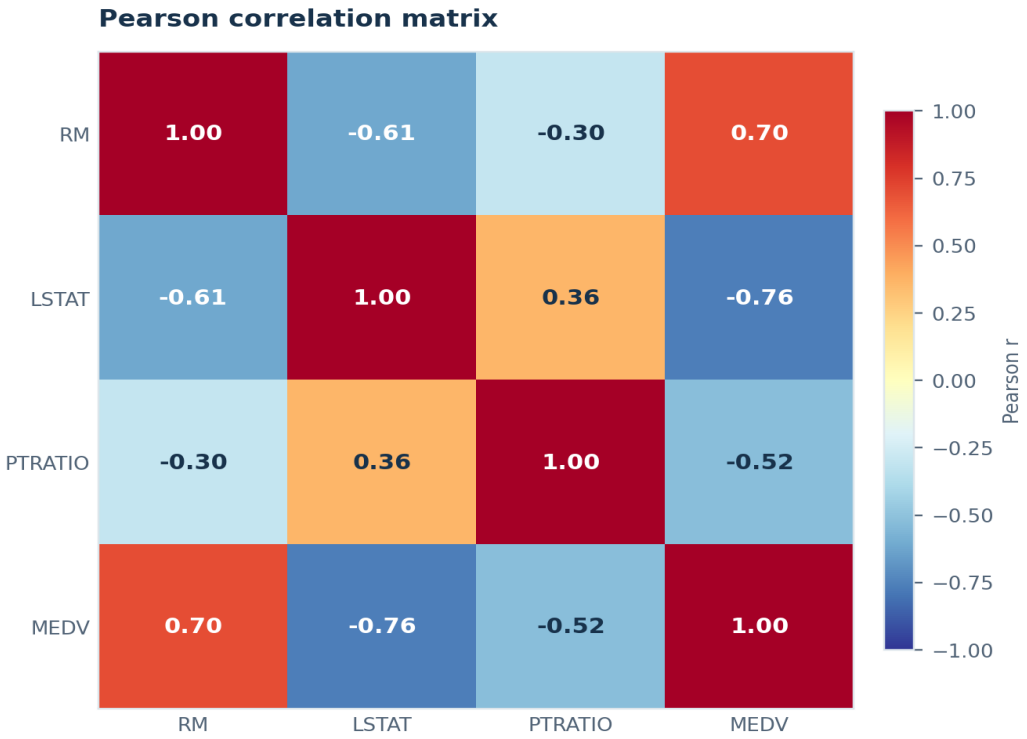
RM et MEDV : association de Pearson positive et modérée (r = 0,697).
LSTAT et MEDV : association de Pearson négative et forte (r = ?0,761).
PTRATIO et MEDV : association de Pearson négative et modérée (r = ?0,519).

La corrélation de Pearson mesure uniquement une association linéaire. Elle ne prouve pas qu'une variable explicative provoque une variation de MEDV ; des relations non linéaires peuvent également exister.



Matrice de corrélation

La carte thermique présente les coefficients de Pearson compris entre ?1 et +1. Les valeurs proches de +1 indiquent une association linéaire positive ; celles proches de ?1 indiquent une association négative ; celles proches de zéro indiquent une faible association linéaire. Cette matrice permet d'examiner le chevauchement entre les variables explicatives et de repérer les relations à étudier plus en détail.

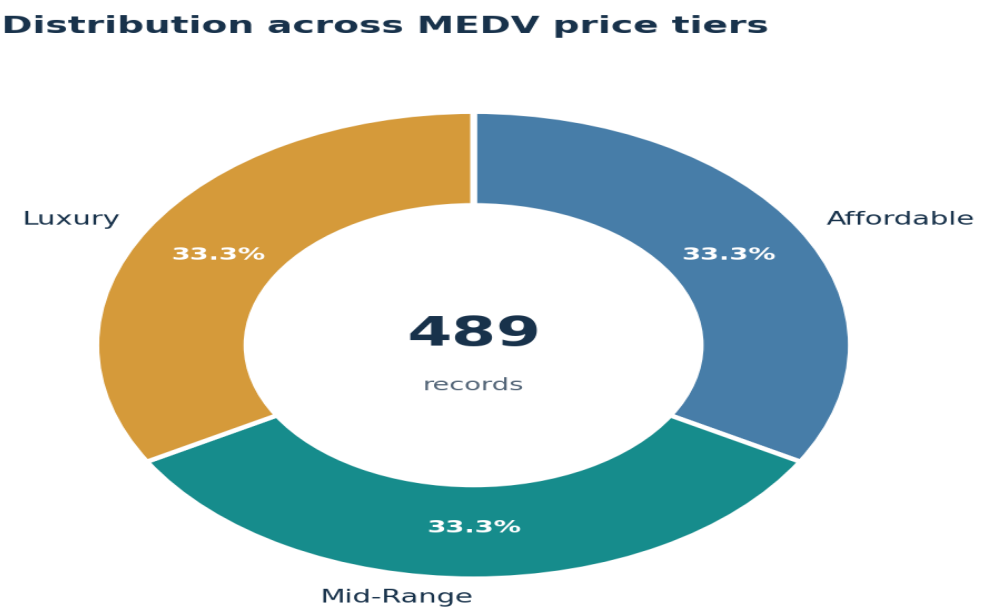


04 | ANALYSES STATISTIQUES
Catégories de prix relatives et vues multivariées

Le tableau de bord déduit trois groupes de prix à partir du classement des valeurs MEDV ; il s'agit de catégories relatives propres à ce jeu de données.

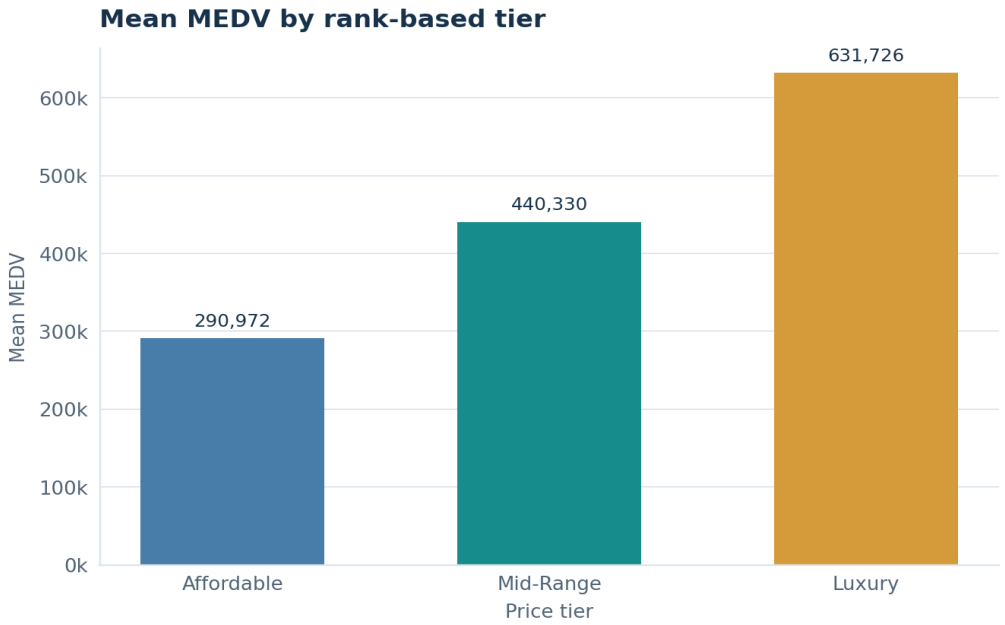
Répartition par catégorie

Les catégories « Abordable », « Gamme intermédiaire » et « Luxe » sont créées en divisant les observations classées selon MEDV en trois groupes approximativement égaux. Elles ne correspondent pas à des segments de marché définis par une source externe. Le diagramme en anneau montre la part des enregistrements attribuée à chaque groupe. Comme MEDV sert lui-même à définir les groupes, les différences de la variable cible entre les catégories sont attendues par construction.



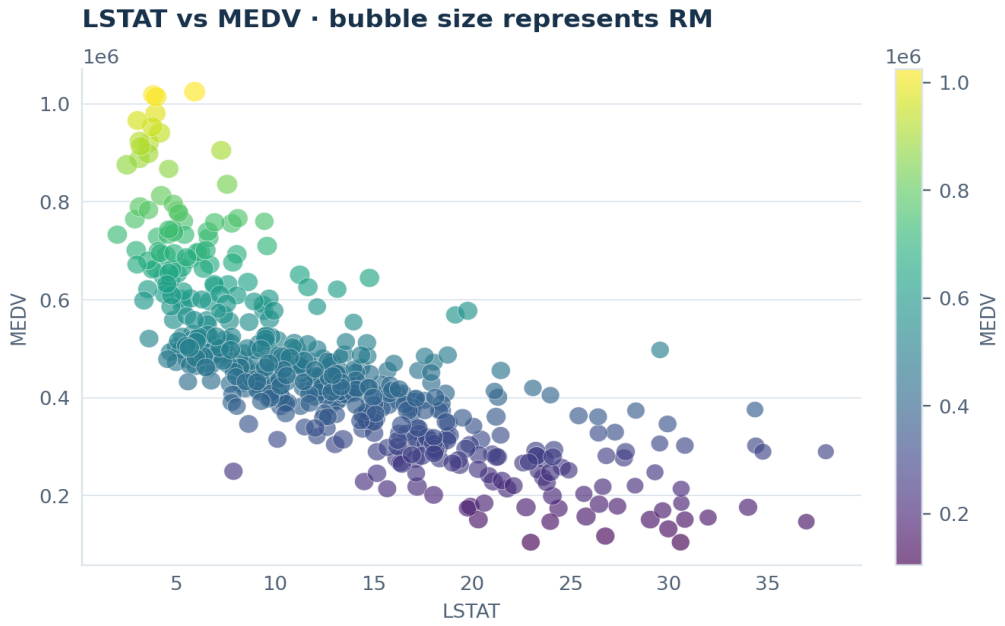
MEDV moyen par catégorie

Le graphique en barres compare la moyenne de MEDV entre les groupes fondés sur le classement. Il s'agit d'un résumé descriptif et non d'une validation indépendante de la segmentation. Il doit être lu avec les distributions afin de comprendre la variabilité à l'intérieur de chaque catégorie.



Vue à bulles à trois variables

Le graphique à bulles place LSTAT sur l'axe horizontal et MEDV sur l'axe vertical ; la taille des marqueurs représente RM et leur couleur représente MEDV. Cette visualisation ajoute une troisième variable, mais le chevauchement des points peut masquer certaines observations individuelles.



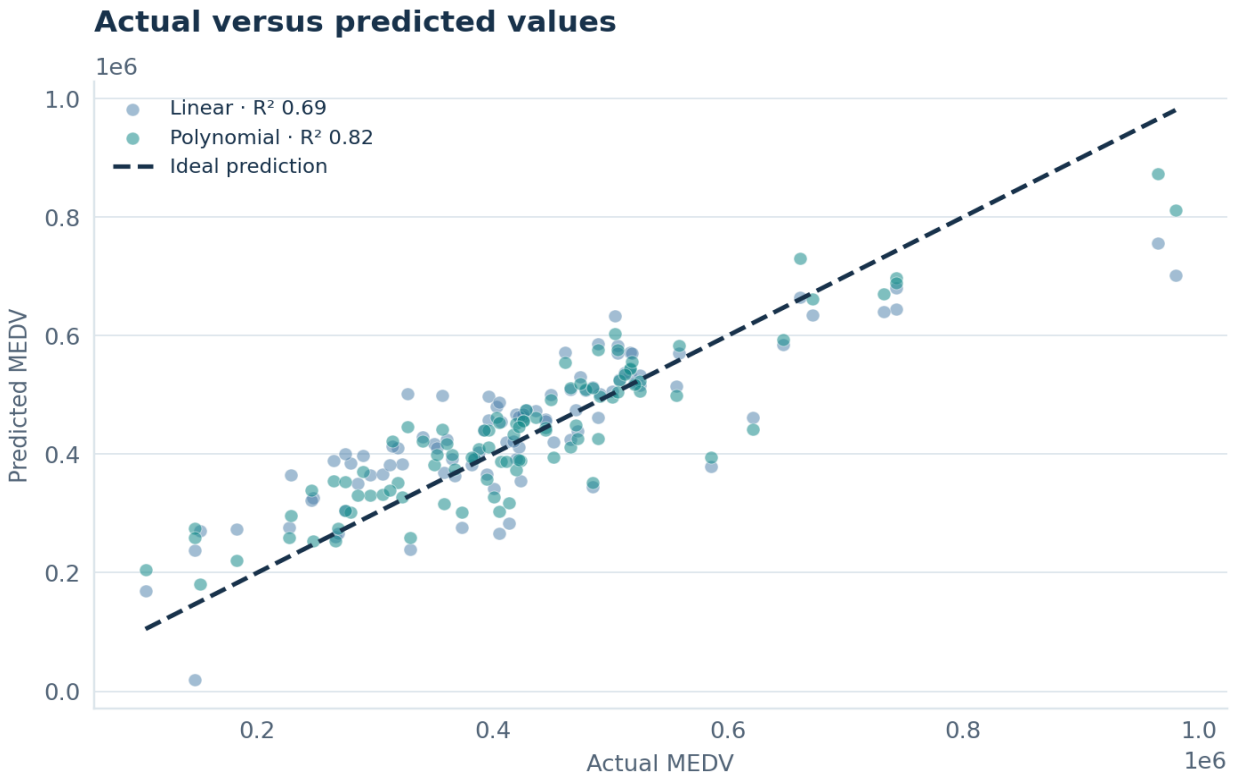
05 | MODÉLISATION PRÉDICTIVE
Régression linéaire et polynomiale

Les deux modèles utilisent la même partition apprentissage/test de 80/20 (random_state = 42) et les trois variables explicatives RM, LSTAT et PTRATIO.

Valeurs réelles et valeurs prédites

Régression linéaire R^2 : 0,691.
Régression polynomiale de degré 2
R^2 : 0,818.

Le pipeline polynomial développe les variables explicatives avec des termes de degré deux avant l'ajustement d'un estimateur linéaire. La diagonale en pointillés représente une prédiction parfaite ; les points plus proches de cette ligne correspondent à des erreurs plus faibles. Le modèle polynomial obtient de meilleurs résultats sur cette partition de test particulière, mais doit être évalué par validation croisée et sur un jeu de test final distinct.



Indicateurs d'évaluation

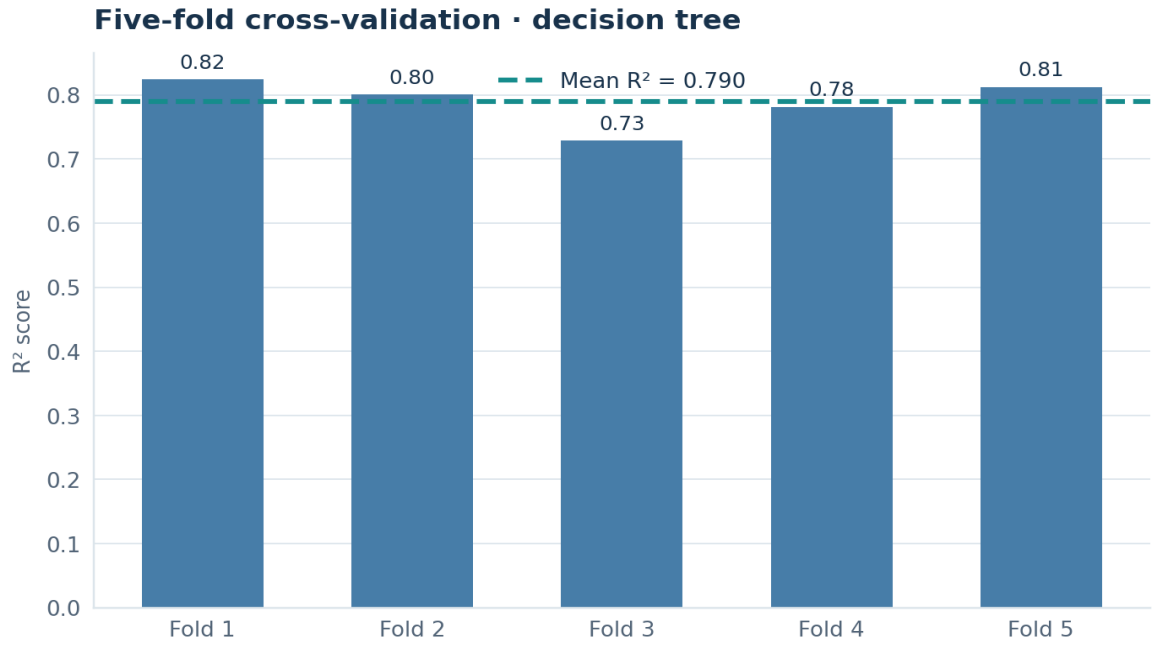
Indicateur	Signification	Sens souhaité
R^2	Part de la variance de la variable cible expliquée sur l'échantillon d'évaluation.	Plus élevé est généralement préférable ; peut être négatif.
MAE	Erreur absolue moyenne de prédiction, exprimée dans l'unité de MEDV.	Plus faible est préférable.
RMSE	Racine carrée de l'erreur quadratique moyenne ; les erreurs importantes sont davantage pénalisées.	Plus faible est préférable.

06 | VALIDATION DES MODÈLES
Validation croisée et complexité du modèle

La validation estime la stabilité du modèle et aide à diagnostiquer l'équilibre entre flexibilité et capacité de généralisation.

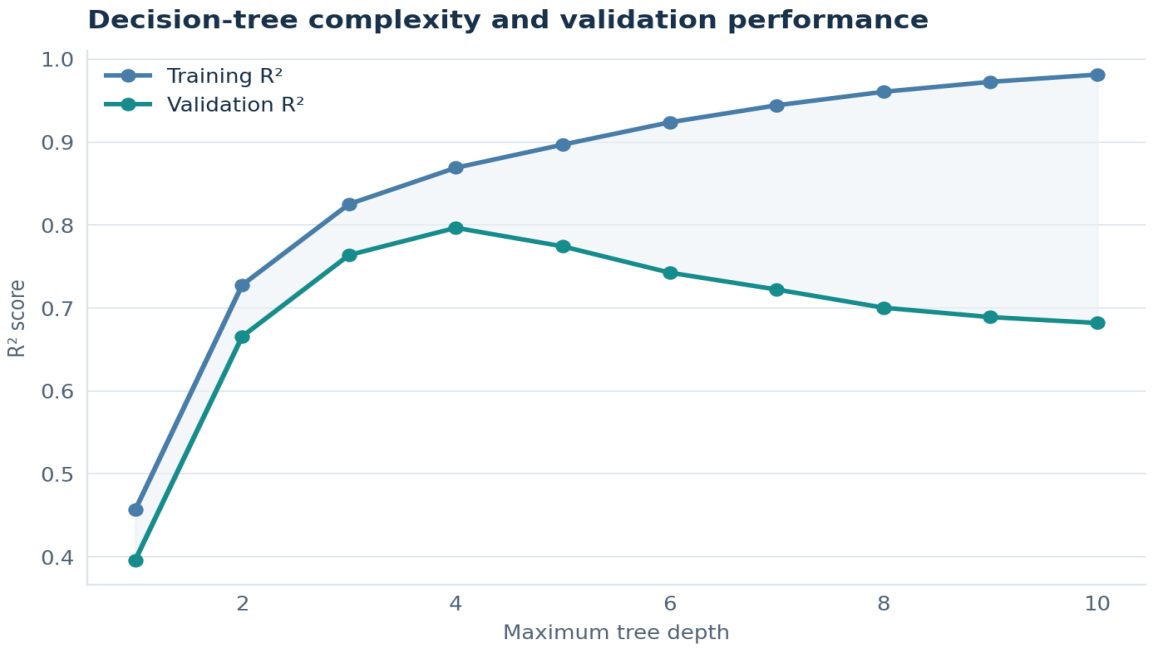
Validation croisée en cinq blocs

Le tableau de bord évalue un arbre de décision de profondeur 5 à l'aide d'une validation K-Fold aléatoire en cinq blocs. Le R^2 moyen est de 0,790 et l'écart-type entre les blocs est de 0,033. Chaque barre représente un bloc de validation. Des scores similaires suggèrent une performance plus stable entre les partitions ; une variation plus importante indique une sensibilité aux échantillons constituant les blocs.



Diagnostic de complexité et de surapprentissage

La courbe de validation fait varier la profondeur maximale de l'arbre de 1 à 10. Le R^2 d'entraînement augmente généralement lorsque l'arbre devient plus flexible. Le R^2 de validation peut s'améliorer, puis se stabiliser ou diminuer. Un écart croissant entre les performances d'entraînement et de validation peut indiquer un surapprentissage. Le seuil d'écart de 0,15 utilisé dans le tableau de bord est une heuristique pratique et non une règle universelle.

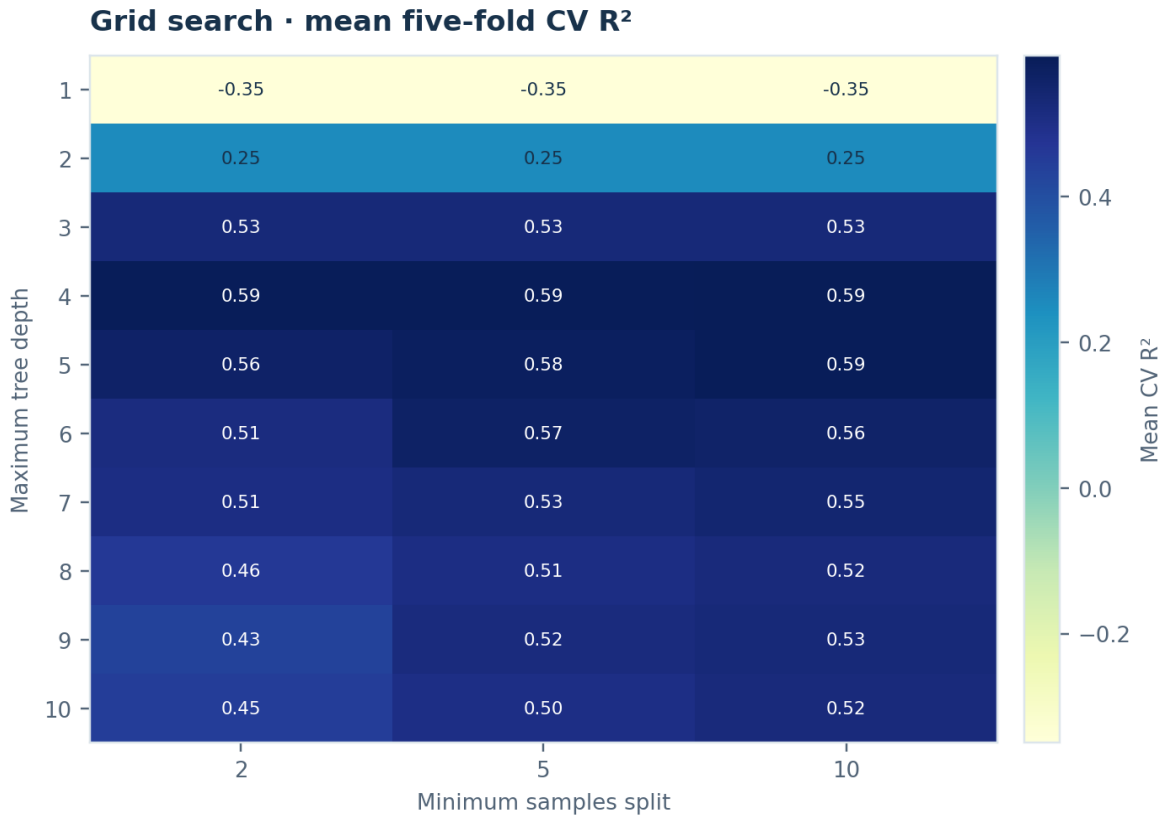


La carte thermique présente le R² moyen de validation croisée en cinq blocs pour les combinaisons de paramètres testées.

Combinaison de paramètres sélectionnée

La recherche teste des profondeurs maximales comprises entre 1 et 10, ainsi que des valeurs de séparation minimale des échantillons de 2, 5 et 10. La meilleure combinaison est : max_depth = 4 et min_samples_split = 10, avec un R² moyen de validation croisée de 0,594. Au total, 30 combinaisons ont été évaluées.

Il s'agit du meilleur résultat parmi les combinaisons testées, et pas nécessairement d'un optimum global. Le score de réglage ne constitue pas une estimation finale sans biais ; il convient de conserver un jeu de test distinct, jamais utilisé, ou d'utiliser une validation croisée imbriquée.



Interprétation de la carte thermique

Les cellules se comparent à l'aide de la même échelle de couleurs. Un R² moyen de validation croisée plus élevé indique une meilleure performance moyenne pour la paire de paramètres considérée. Lorsque plusieurs réglages donnent des résultats proches, un arbre plus simple et moins profond peut être préférable pour faciliter l'interprétation et améliorer la stabilité.

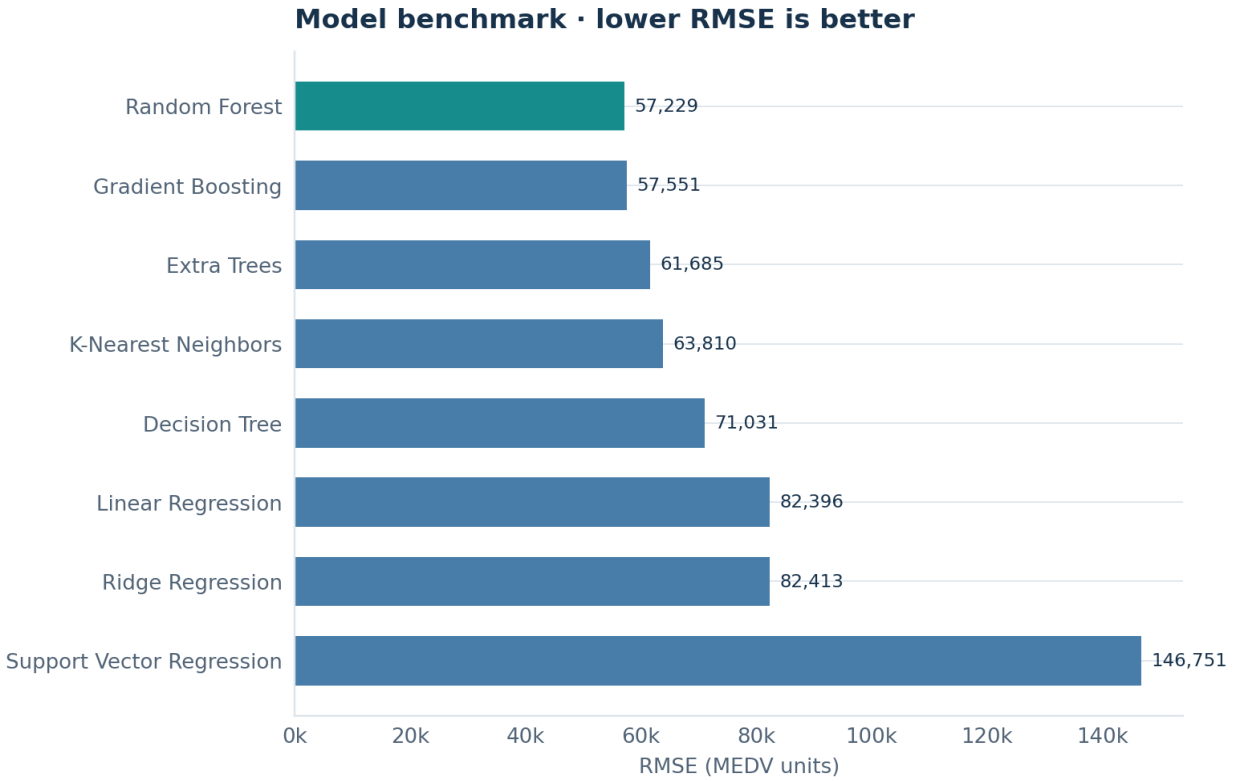
08 | COMPARAISON DES ALGORITHMES
Huit algorithmes de régression sur un jeu de test commun

Tous les modèles utilisent la même partition apprentissage/test de 80/20 et random_state = 42 afin de permettre une comparaison équitable.

Interprétation du benchmark

Meilleur modèle selon la RMSE : Random Forest.
R^2 : 0,851
MAE : 44 053
RMSE : 57 229

Gradient Boosting obtient un résultat proche de Random Forest dans cette exécution. L'écart entre les algorithmes les plus performants et les moins performants montre que le choix du modèle compte pour ce jeu de données et cette partition. Le classement peut changer avec un autre échantillon, de nouvelles données ou un prétraitement révisé.



Performance des modèles (triée par RMSE)

Modèle	R^2	MAE	RMSE
Random Forest	0,851	44 053	57 229
Gradient Boosting	0,849	44 113	57 551
Extra Trees	0,827	47 241	61 685
K plus proches voisins (KNN)	0,815	48 763	63 810

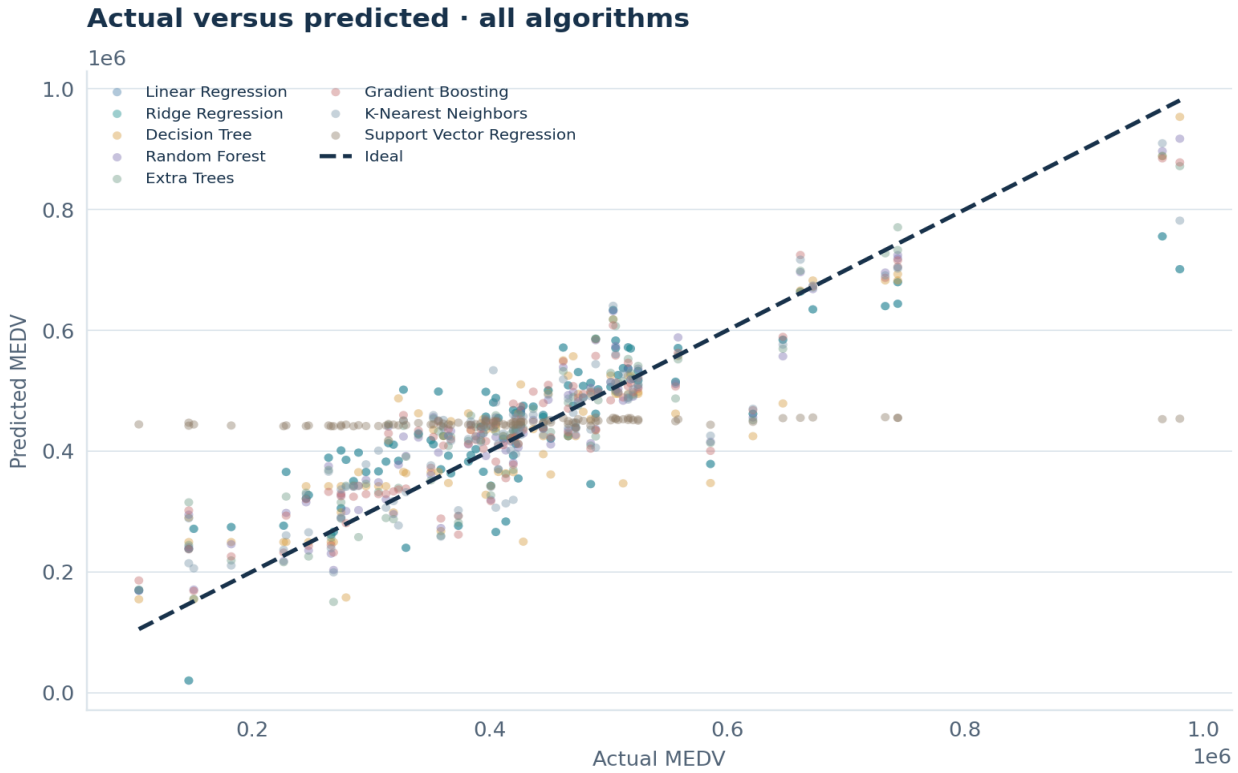
Modèle	R^2	MAE	RMSE
Arbre de décision	0,770	53 041	71 031
Régression linéaire	0,691	64 277	82 396
Régression Ridge	0,691	64 276	82 413
Régression par vecteurs de support (SVR)	0,020	106 379	146 751

09 | DIAGNOSTIC DES PRÉDICTIONS
Ajustement des prédictions et contribution des variables

Les graphiques de prédiction permettent de repérer la dispersion, les biais systématiques et les contributions propres aux variables selon le modèle.

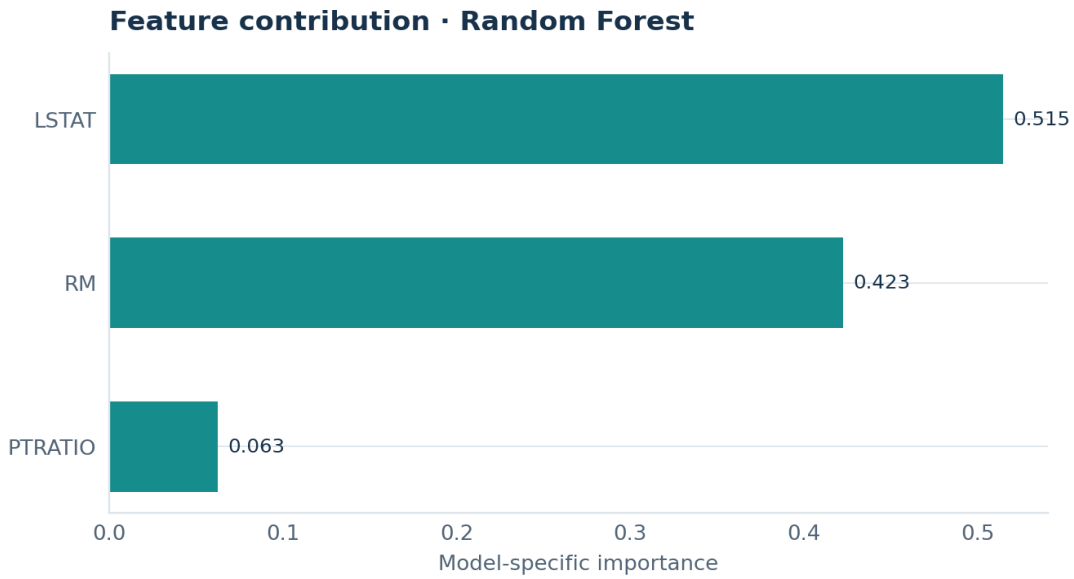
Valeurs réelles et prédites ? tous les modèles

Chaque point compare une valeur réelle de l'échantillon de test à une prédiction du modèle. La diagonale en pointillés représente un accord parfait. Des points systématiquement au-dessus ou au-dessous de la ligne peuvent indiquer une surestimation ou une sous-estimation dans certaines plages de la variable cible. Comme les algorithmes se chevauchent, il convient d'examiner les graphiques de chaque modèle avant toute utilisation opérationnelle.



Importance des variables / coefficients absolus

Le modèle sélectionné est Random Forest. Le graphique présente l'importance des variables propre au modèle ou les coefficients absolus, selon le type d'estimateur. Ces mesures ne sont pas nécessairement comparables entre algorithmes et n'établissent pas de relation causale.



10 | CONCLUSIONS ET RECOMMANDATIONS

Conclusions fondées sur les résultats et prochaines étapes

Il convient de distinguer les tendances descriptives, les performances prédictives et les affirmations causales.

Éléments probants	Interprétation
489 enregistrements ; 4 variables numériques ; aucune valeur manquante ni ligne exactement dupliquée dans les colonnes requises.	L'analyse est complète pour les quatre variables fournies, mais l'ensemble des variables explicatives reste limité.
Random Forest obtient un R^2 de 0,851 sur l'échantillon de test.	Il arrive en tête selon la RMSE sur cette partition reproductible 80/20 spécifique.
R^2 polynomial = 0,818 ; R^2 linéaire = 0,691.	Les termes de degré deux améliorent l'ajustement sur l'échantillon de test par rapport au modèle linéaire simple dans cette exécution.
Meilleur R^2 de validation croisée de la recherche sur grille = 0,594.	Les paramètres retenus sont les meilleurs parmi les combinaisons testées, sans être nécessairement optimaux à l'échelle globale.
La corrélation et l'importance des variables sont des mesures d'association.	Aucune des deux ne prouve qu'une modification d'une variable explicative entraînera une variation de MEDV.

Recommended workflow

1. Documenter les définitions : confirmer la signification, l'unité, la devise, la date et la provenance de MEDV et LSTAT.
2. Examiner les observations inhabituelles : vérifier les valeurs signalées par l'IQR à partir des données sources ; ne pas les supprimer automatiquement.
3. Conserver un modèle de référence : comparer les algorithmes non linéaires à une régression linéaire interprétable.
4. Valider de manière robuste : utiliser une validation croisée répétée ou imbriquée et conserver un jeu de test final totalement indépendant.
5. Améliorer les variables disponibles : ajouter des variables uniquement lorsque leurs définitions, leur qualité et leur disponibilité sont documentées. Le CSV actuel ne contient aucune information sur la localisation, l'âge ou le type de propriété.
6. Communiquer l'incertitude : présenter les erreurs dans les unités documentées de la variable cible et éviter de présenter les estimations du modèle comme des évaluations immobilières officielles.

Reproductibilité : le tableau de bord fourni utilise des graines aléatoires fixes pour sa partition principale et ses paramètres de modèle. Ce rapport a été calculé à partir du fichier CSV fourni, en utilisant les principaux algorithmes et paramètres définis dans le code Python fourni. De légères différences peuvent apparaître selon les versions des logiciels.

Sources : dashboard_housing(2).py et housing(1).csv fournis dans cette conversation. Aucune donnée externe n'a été ajoutée.